UNIVERSIDADE FEDERAL DE UBERLÂNDIA

FACULDADE DE COMPUTAÇÃO

DISCIPLINA: CIÊNCIA DE DADOS II

ARTHUR AQUINO GUARDIEIRO

GUILHERME ANTONIO GARCIA DO NASCIMENTO

RODRIGO MARTINS DE SOUZA

AGRUPAMENTO DE BOLETINS DE OCORRÊNCIA UTILIZANDO ALGORITMOS DE CLUSTERIZAÇÃO

Uberlândia

2026

1 INTRODUÇÃO

A análise de dados públicos tem se consolidado como ferramenta relevante para compreender fenômenos sociais complexos, como a criminalidade. No contexto da segurança pública, os boletins de ocorrência reúnem informações sobre natureza do delito, local, data, horário e características do fato, permitindo investigar padrões que não são facilmente percebidos por inspeção manual.

Neste trabalho, utiliza-se uma abordagem de ciência de dados com técnicas de análise exploratória, testes estatísticos e aprendizado não supervisionado para estudar registros de Minas Gerais disponibilizados no Portal de Dados Abertos. A proposta está organizada em três eixos: identificação de padrões temporais e espaciais gerais das ocorrências; análise da concentração de ocorrências com arma de fogo por período e por região; e avaliação da associação entre tipo de local e crimes violentos.

A estrutura do relatório segue o pipeline implementado no notebook: descrição da base, pré-processamento, análise exploratória, modelagem por clusterização, validações estatísticas e interpretação dos resultados.

2 DESCRIÇÃO DOS DADOS

Os dados utilizados neste relatório foram obtidos no Portal de Dados Abertos do Estado de Minas Gerais, que disponibiliza à sociedade registros oficiais de boletins de ocorrência. A base analisada reúne informações estruturadas sobre criminalidade em diferentes municípios do estado, permitindo análises com recortes temporal, espacial e temático.

A unidade de análise do conjunto não corresponde a ocorrências individuais, mas a registros agregados. Esse caráter agregado é representado pela variável **"qtde ocorrencias"**, que indica o total de boletins associados a uma determinada combinação de atributos. Assim, cada linha da base representa um agrupamento de ocorrências com características comuns.

Para aprofundar a investigação, foram construídas variáveis indicadoras derivadas dos dados originais. A variável **"usa_arma_fogo"** foi definida de forma binária a partir de busca textual em **"descricao_longa_meio_utilizado"**, identificando menções a arma de fogo. Já a variável **"crime_violento"** também foi construída de forma binária com base em padrões textuais de **"natureza_principal_completa"**, incluindo categorias como homicídio, roubo, latrocínio, estupro, lesão corporal, sequestro e extorsão.

Como a base é agregada, as proporções e medidas de associação foram calculadas de forma ponderada por **"qtde ocorrencias"**, de modo a refletir a frequência real dos eventos. Predominam variáveis categóricas no conjunto de dados; por isso, foram empregadas técnicas de análise de frequência, clusterização não supervisionada (K-Means), testes de independência (qui-quadrado), medidas de associação (V de Cramér) e métricas de diversidade (entropia), com o objetivo de identificar padrões estruturais espaço-temporais da criminalidade.

3 METODOLOGIA

A metodologia aplicada neste trabalho foi estruturada em um fluxo de preparação, modelagem e validação dos dados. Na etapa de pré-processamento, os arquivos foram integrados em um único **'dataset_combinado'**, com padronização das colunas por meio do **'mapa_colunas'** e exclusão de variáveis que não eram úteis por meio do **'colunas_remover'**. A variável temporal **'data_fato'** foi limpa utilizando **'data_fato_limpa'** e convertida em **'data_fato_dt'** (com tentativa em múltiplos formatos) e padronização final para ser utilizada no código. Também foi criada a variável categórica **'faixa_horaria'** a partir de **'horario fato'** convertendo os registros em Madrugada, Manhã, Tarde e Noite.

Na análise exploratória, a variável de peso **'qtde ocorrencias'** foi utilizada para estimativas ponderadas, evitando distorções por simples contagem de linhas. Foram montadas tabelas por **'dia_semana_fato'** e **'faixa_horaria'** e construídos heatmaps tanto em escalas absolutas quanto em escala proporcionais para melhor análise dos dados. Os atributos 'usa_arma_fogo' que foram gerados a partir de **'descricao_longa_meio_utilizado'** e **'crime_violento'** gerado a partir de **'natureza_principal_completa'** foram utilizados para aprofundar a dimensão temática do trabalho. Essas variáveis permitiram calcular os indicadores de **'p_arma_fogo', 'arma_por_faixa', 'arma_por_risp', 'arma_risp_faixa', 'p_violento'** e **'violencia_por_local'** além de análises por 'tipo_local' e filtros por volume mínimo.

A EDA combina estatísticas descritivas, análise de distribuição de **'qtde ocorrencias'** (histograma e boxplot), heatmaps de volume e de proporções por **'dia_semana_fato** x **faixa_horaria'**, além de matrizes de correlação (Pearson e Spearman) para variáveis numéricas disponíveis.

Quanto a modelagem foi construída uma matriz de perfil temporal município com agregação de **'municipio'** e **'faixa_horaria',** normalização por linha e padronização por StandardScaler para gerar X. Foi aplicado o K-Means com avaliação do número de grupos por inércia utilizando o Método do Cotovelo e por Silhuete Score, chegando ao modelo final **'K_FINAL'** e ao conjunto **'df_cluster_final'** com rótulos **'cluster'.** A interpretação foi feita por **'perfil_cluster'**, municípios representativos e associação espacial com risp (d**f_cluster_geo, tabela_cluster_risp**). Por fim, a validação estatística **chi2_contingency** em tabelas de contingência (**tabela_arma, tabela_horario, tabela_risp, tabela_local**), magnitiude de efeito por **cramers_v/cramers_v_matrix** e análise de concentração e diversidade por entropia (**diversidade**), consolidado evidências sobre padrões espaço-temporais e tipológicos da criminalidade.

4 RESULTADOS

4.1 Heatmap (Proporção) - Crimes por Dia da Semana e Faixa Horária

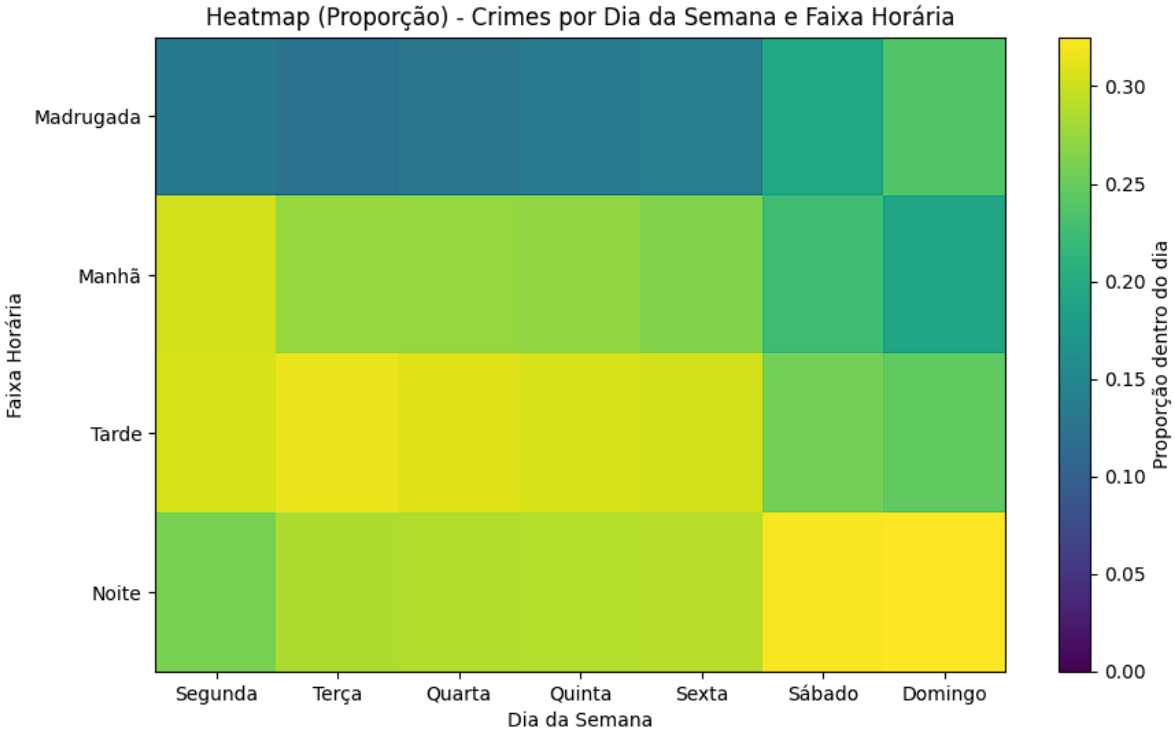

Figura 1 - Distribuição proporcional das ocorrênmcias por faixa horária dentro de cada dia da semana (ponderado por **qtde ocorrencias**).

A Figura 1 apresenta a distribuição proporcional das ocorrências ao longo das faixas horárias. É possível observar que existe predominância do período da tarde durante os dias úteis, enquanto nos finais de semana, há aumento da participação relativa do período noturno. Isso indica que o padrão temporal de criminalidade geral varia conforme o dia da semana, acompanhando a dinâmica social e urbana.

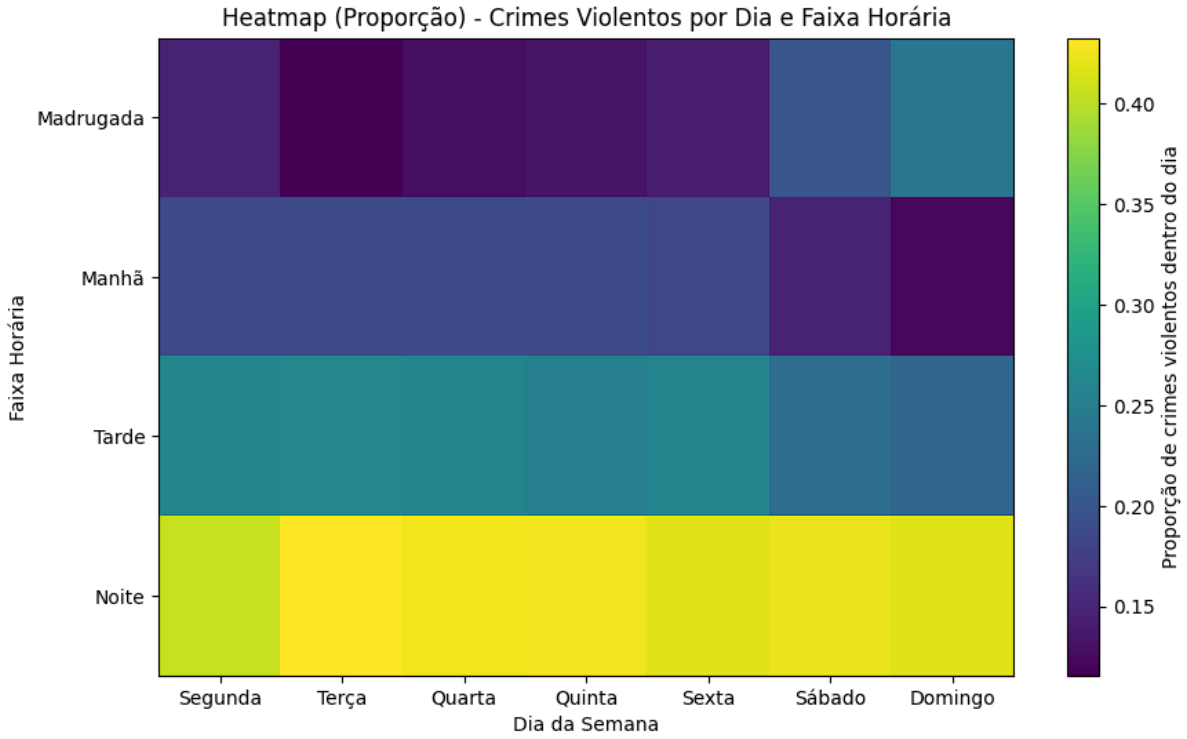

Figura 2 - Distribuição proporcional de crimes classificados violentos por fixa horária e dia da semana.

Os crimes violentos apresentam concentração consistente no período noturno ao longo de toda semana. Diferentemente do padrão geral da Figura 1, a violência mostra perfil temporal mais restrito, com predominância noturna inclusive em dias úteis.Esse padrão é coerente com a literatura criminológica, que aponta maior incidência de crimes patrimoniais e violentos em períodos de maior circulação populacional e atividades noturnas.

4.2 Uso de Arma de Fogo

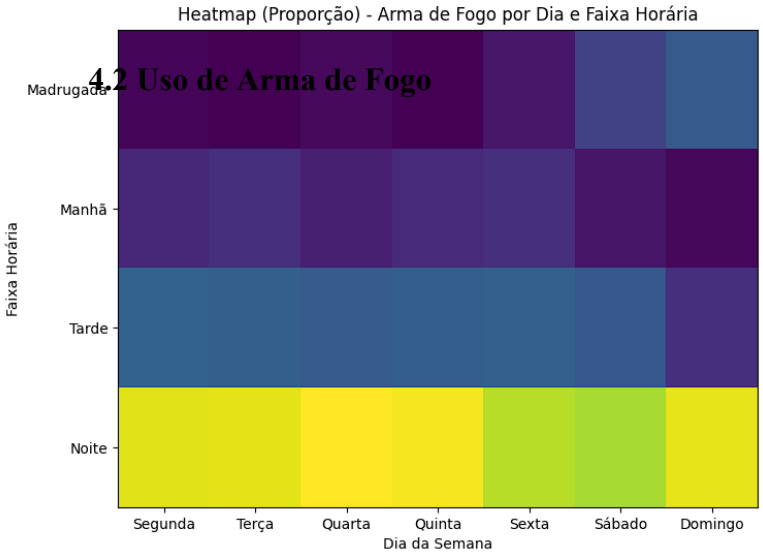

risp	
RISP 2 - CONTAGEM	0.005491
RISP 19 - SETE LAGOAS	0.003508
RISP 1 - BH	0.003237
RISP 6 - LAVRAS	0.003202
RISP 3 - VESPASIANO	0.003044
RISP 7 - DIVINÓPOLIS	0.002326
RISP 18 - POÇOS DE CALDAS	0.002145
RISP 10 - PATOS DE MINAS	0.002082
RISP 16 - UNAÍ	0.002029
RISP 9 - UBERLÂNDIA	0.001999
RISP 11 - MONTES CLAROS	0.001970
RISP 12 - IPATINGA	0.001910
RISP 5 - UBERABA	0.001839
RISP 17 - POUSO ALEGRE	0.001718
RISP 14 - CURVELO	0.001704
RISP 8 - GOV. VALADARES	0.001702
RISP 4 - JUIZ DE FORA	0.001521
RISP 15 - TEÓFILO OTONI	0.001260
RISP 13 - BARBACENA	0.001116

Figura 3 - Distribuição proporcional de crimes classificados violentos por turno, frequência ,dia da semana e por RISP(Regiões Integradas de Segurança Pública).

Participação de ocorrências com usa_arma_fogo = 1 por faixa horária (ponderada por qtde ocorrencias). O resultado indica diferença entre períodos do dia na incidência relativa de eventos com arma de fogo.

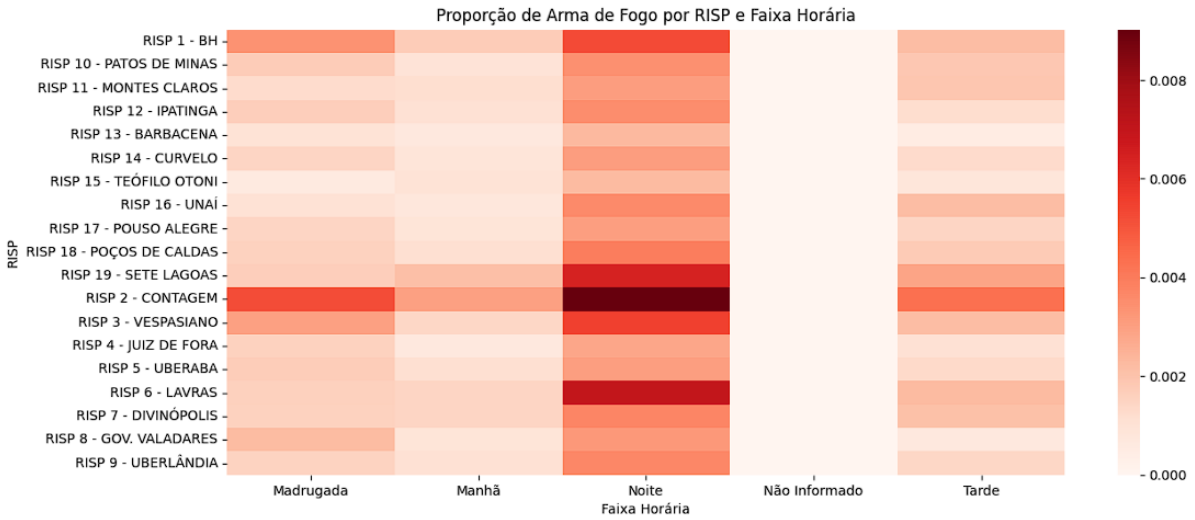

Figura 4 - Arma de Fogo por RISP e Faixa Horaria.

Participação de ocorrências com arma de fogo por região de segurança pública (RISP). Observa-se variação regional, sugerindo padrões territoriais distintos na distribuição desse tipo de ocorrência.

4.3 Crimes Violentos e Tipo de Local

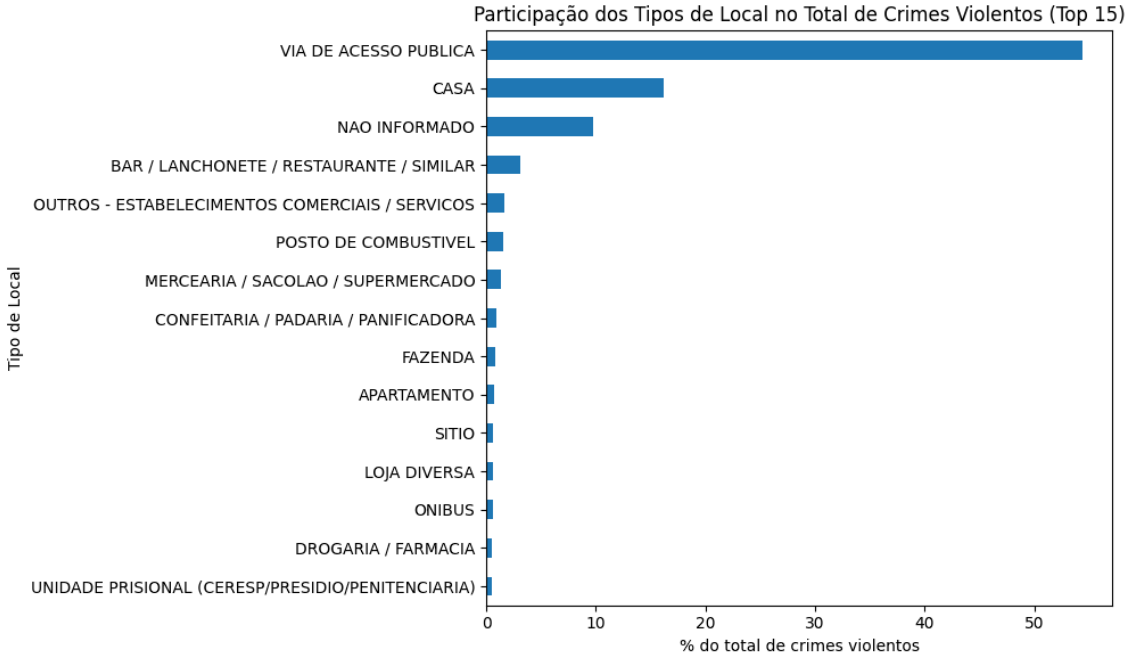

Figura 5 - Top 15 de Participação dos Tipos de Local no Total de Crimes Violentos.

Proporção de crime_violento = 1 por tipo_local (com filtro de volume mínimo). Os resultados mostram que a participação relativa de crimes violentos varia conforme o contexto do local de ocorrência.

4.4 Clusterização dos Municípios

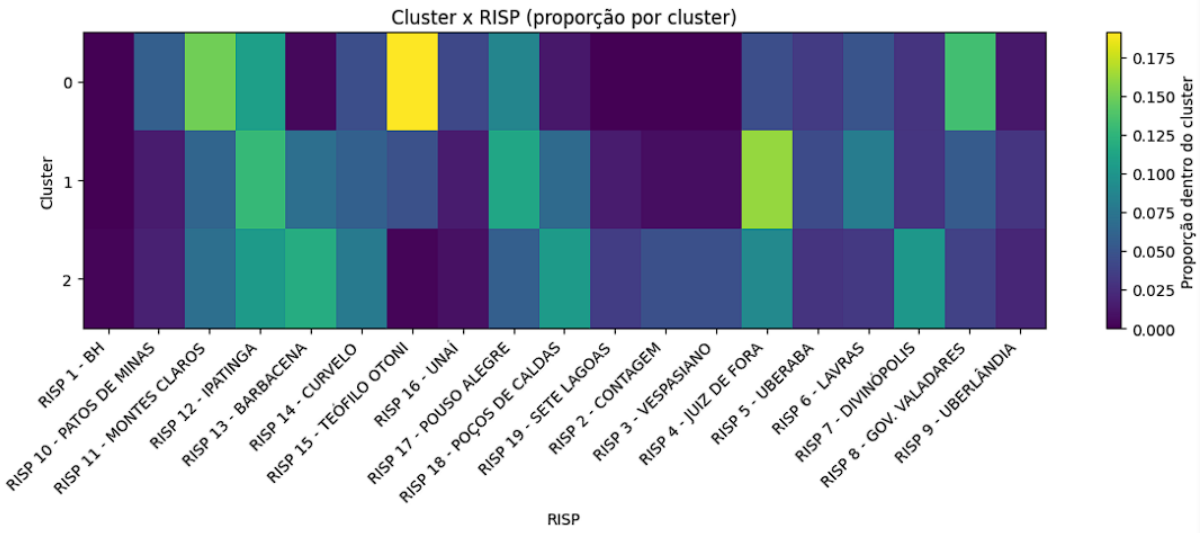

Figura 6 - Clusterização dos Municípios.

Distribuição dos clusters por RISP. A associação entre perfil temporal e região reforça a existência de heterogeneidade espacial na organização dos padrões identificados. O índice de concentração indicou que algumas RISPs apresentaram forte predominância de um único cluster, como observado na **RISP 1 – Belo Horizonte**, cujo índice foi igual a 1,00, sugerindo homogeneidade estrutural interna.

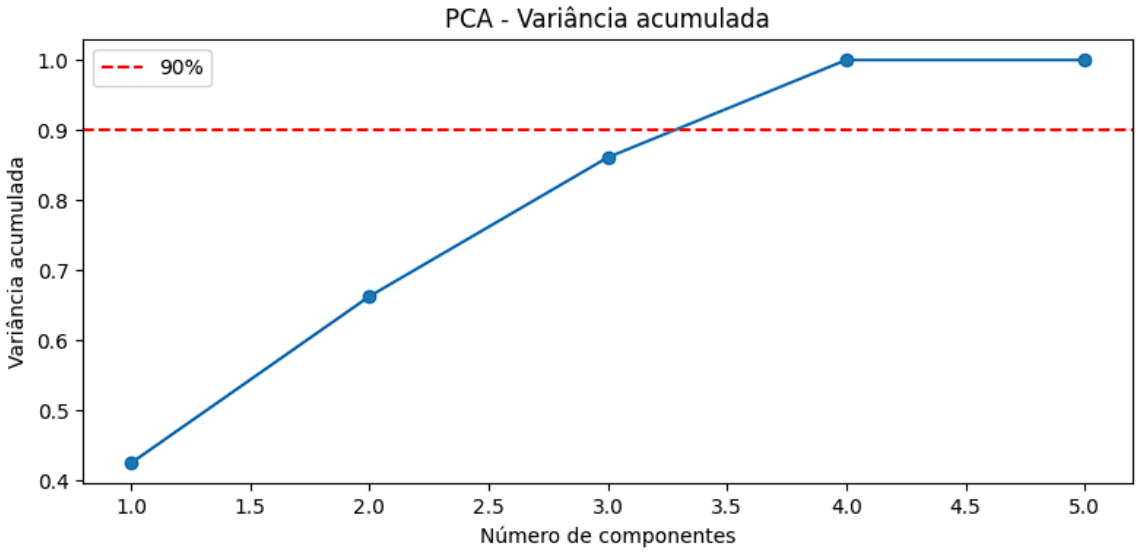

Figura 7 - PCA da Variância acumulada.

Variância explicada acumulada pelos componentes principais. O gráfico é utilizado como evidência complementar de estrutura nos dados e suporte à robustez da etapa de modelagem.

5 DISCUSSÕES E CONCLUSÕES

Os resultados mostram que a dinâmica criminal não é homogênea entre períodos do dia, dias da semana e regiões. A combinação de análise descritiva ponderada, testes estatísticos e clusterização permitiu identificar padrões relevantes de forma complementar. A inclusão de PCA e métricas adicionais de cluster fortalece a avaliação metodológica, enquanto o teste de estabilidade por múltiplas sementes aumenta a confiabilidade dos agrupamentos.

Como principais limitações, destacam-se a natureza agregada da base, a dependência de regras textuais para criação de variáveis binárias e possíveis inconsistências de preenchimento dos registros administrativos. Como continuidade, recomenda-se incorporar recortes longitudinais e variáveis contextuais adicionais para aprofundar a interpretação dos padrões identificados.